Introdução a paralelização de aplicações com OpenMP

Rodrigo Alves Prado da Silva

¹Instituto de Computação Universidade Federal Fluminense

ERAD RJ 2018

Quem sou eu?



Rodrigo Silva (Foto ilustrativa)

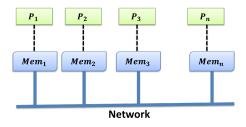
- Bacharel em Ciência da Computação pela UFF.
- Mestrando pela mesma instituição.
- Trabalha com computação distribuída, HPC, cloud computing e paralelismo com MPI, OpenMP e instruções SIMD.

Citação

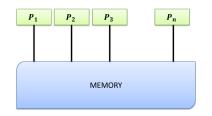
Não importa o quão rápido os computadores são. Neste momento, novas tecnologias estão sendo desenvolvidas para que eles sejam ainda mais rápidos. Nosso apetite por processamento e capacidade de memória parece insaciável.

Chapman et al. (2008)

Memória Distribuida vs Memória Compartilhada



Arquitetura de memória distribuída.

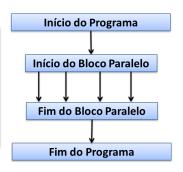


Arquitetura de memória compartilhada.

Introdução ao OpenMP

O que é OpenMP?

- Sistemas de memória compartilhada
- Diretivas
- Funções
- Variáveis de Ambiente
- ► Fork-Join



Algumas bibliotecas

► MPI, Pthreads, OpenMP, OpenCL, CUDA

Por que OpenMP?

Razões técnicas:

- ▶ Linguagens suportadas: Fortran e C/C++
- Mesmo código para implementação serial e paralela
- Implementação portátil e intuitiva

Por que OpenMP?

Por que deveríamos paralelizar nossos códigos:

- Quantos cores tem o seu computador?
- Os programas que você escreve aproveitam TODO o poder processamento disponível?
- Você quer ganhar desempenho?

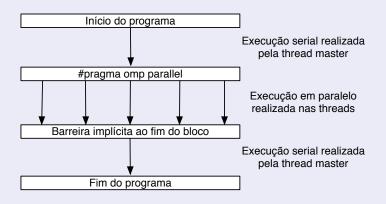
Principais Componentes do OpenMP

- Diretivas
 - ► #pragma omp parallel
 - ► #pragma omp master
 - ► #pragma omp single
 - ► #pragma omp for
 - ► #pragma omp critical
 - ► #pragma omp atomic
 - Etc
- Biblioteca
 - omp_get_num_threads()
 - omp_set_num_threads()
 - omp_get_thread_num()
- Variáveis de ambiente
 - OMP_NUM_THREADS

Expressando paralelismo

Bloco paralelo

- ► #pragma omp parallel
- Inicia bloco de código que será executado por todas as threads disponíveis



Hello World Paralelo

- A execução é inicializada na thread master
- ► A diretiva #pragma omp parallel inicia um bloco paralelo (fork)
- ► Cada thread executa os comandos contidos no bloco paralelo
- ► Barreira implícita ao fim do bloco (join)
- Thread master retoma o processamento serial
- ▶ gcc -fopenmp -o <exe> <source.c>

Hello World

Perguntas:

O que acontece na linha 11 do exemplo helloworld.c?

- O que acontece na linha 11 do exemplo helloworld.c?
- Como paralelizar um bloco de código maior?

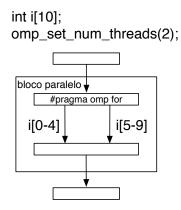
- O que acontece na linha 11 do exemplo helloworld.c?
- 2 Como paralelizar um bloco de código maior?
- Ocomo preparar um código OpenMP para máquinas que não tem a biblioteca instalada?

- O que acontece na linha 11 do exemplo helloworld.c?
- 2 Como paralelizar um bloco de código maior?
- Ocomo preparar um código OpenMP para máquinas que não tem a biblioteca instalada?
- O que é escrito na tela na execução da linha 19, helloworld3.c?

- O que acontece na linha 11 do exemplo helloworld.c?
- 2 Como paralelizar um bloco de código maior?
- Ocomo preparar um código OpenMP para máquinas que não tem a biblioteca instalada?
- O que é escrito na tela na execução da linha 19, helloworld3.c?
- Como alterar o número de threads sem alterar o código?
 - export OMP_NUM_THREADS=N

Divisão de um vetor

► Como dividir o trabalho a ser realizado em um vetor entre as *threads* disponíveis?



Contexto dos Dados

- Contexto das threads
 - Variáveis locais
 - Variáveis globais
- Variáveis privadas
 - Private
 - Firstprivate
- Variáveis compartilhadas
 - Default
 - Shared
- Variáveis de ambiente
 - OMP_STACKSIZE
 - ▶ Default: entre 2MB e 4MB

Contexto de variáveis

- ► Inicialização da variável X
- ► Criação de 20 threads

Pergunta: Qual o comportamento esperado da programa?

Reduções

Redução é uma operação computacional que, aplicada a um conjunto de valores, resulta em um único valor.

Contexto de variáveis

- ► Soma: $[1, 2, 3, 4, 5] \rightarrow 15$
- ▶ Multiplicação: $[1, 2, 3, 4, 5] \rightarrow 120$
- ► Mínimo: $[1, 2, 3, 4, 5] \rightarrow 1$
- ▶ Máximo: $[1, 2, 3, 4, 5] \rightarrow 5$

Redução de um vetor

- Dado um vetor de N posições
- ► Retornar a soma dos valores contidos em cada uma das N posições

Pergunta: Como esta tarefa pode ser dividida?

Sincronização

Como estabelecer uma ordem na execução das threads?

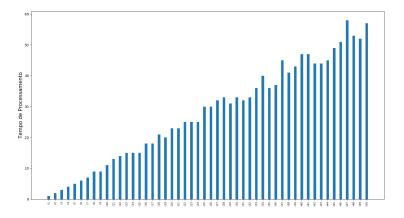
Barreira

- ► #pragma omp barrier
- ▶ Todas as threads devem alcançar a barreira para que a execução possa seguir
- Garante consistência

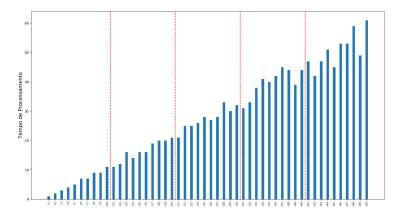
Sessão crítica

- ► #pragma omp critical
- ▶ Trecho executado por somente uma *thread* por vez
- Garante exclusão mútua, evita condição de corrida

O ocorre quando o processamento das iterações não é constante?



O ocorre quando o processamento das iterações não é constante?



Escalonamento Estático

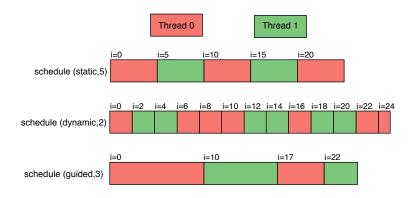
- Escalonamento default
- Chunksize default = número de iterações / número de threads
- #pragma omp parallel for schedule(static[,chunksize])

Escalonamento Dinâmico

- ► Chunksize default = 1
- #pragma omp parallel for schedule(dynamic[,chunksize])

Escalonamento Guiado

- ▶ Compilador define tamanho dos chunks, de forma decrescente
- Lastchunksize define o tamanho do último chunk
- #pragma omp parallel for schedule(guided[,lastchunksize])



Contar números primos

- ► Dado um valor N
- ▶ Qual o número de primos no intervalo [1,N]?

Perguntas:

Como dividir este problema?

Contar números primos

- Dado um valor N
- ▶ Qual o número de primos no intervalo [1,N]?

- Como dividir este problema?
- Esta solução está correta?

Contar números primos

- Dado um valor N
- ▶ Qual o número de primos no intervalo [1,N]?

- Como dividir este problema?
- Esta solução está correta?
- ► Todas as threads terão o mesmo trabalho?

Outras formas de divisão de trabalho

- Como paralelizar problemas irregulares?
 - Algoritmos recursivos
 - Loops sem limite definido

Seções

- ► #pragma omp sections
- Define seções a serem processadas por uma única thread
- Threads executam seções sequencialmente

Tarefas

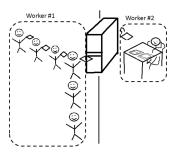
- ► #pragma omp task
- Tarefas são criadas de acordo com uma determinada condição
- Threads executam tarefas sequencialmente
- Padrão Producer-Consumer

Padrão produtor-consumidor

- Lista é preenchida com itens produzidos em tempo de execução
- Itens da lista são consumidos
- Tempo de consumo é variável
- ► Tempo de produção é sempre menor que o tempo de consumo

Pergunta:

► Como dividir este problema?

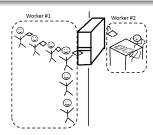


Tarefas

- Como paralelizar problemas irregulares?
 - Algoritmos recursivos
 - Loops sem limite definido

Tarefa

- ► #pragma omp task
- Tarefas são criadas de acordo com uma determinada condição
- Threads executam tarefas sequencialmente
- ► Padrão Producer-Consumer



Desafio!

Mutually Friendly Numbers

Dois números são considerados *mutually friendly* se a razão entre a soma de todos os divisores de um número e ele próprio é igual a mesma razão do outro número.

Exemplo:

$$\frac{1+2+3+5+6+10+15+30}{30} = \frac{72}{30} = \frac{12}{5}$$

$$\frac{1+2+4+5+7+10+14+20+28+35+70+140}{140} = \frac{336}{140} = \frac{12}{5}$$

30 e 140 são mutually friendly

Problema:

Dados um limite inferior e um limite superior, retornar todos os números *mutually friendly* contidos no intervalo.

Desafio!

Detalhes da máquina

- ▶ 12 cores lógicos
- ▶ 32 GB RAM

Soluções

- ► Enviar código-fonte para rodrigo_prado@id.uff.br
- Dúvidas?

Referências

- ► Chandra, Rohit. Parallel programming in OpenMP. Morgan Kaufmann, 2001.
- http://openmp.org

Dúvidas e Sugestões

rodrigo_prado@id.uff.br

Agradecimentos

Agradeço ao Luan Teylo e o Leonardo Oliveira pelo material disponibilizado.

GitHubs:

https://github.com/luanteylo/minicurso-OpenMP/

Meu GitHub

Esta apresentação e o material apresentado no curso estão no GitHub apresentado abaixo:

https://github.com/rodrigo-prado/introducao-openmp/